

Solución Paso a Paso: Problema de Redes Neuronales con Adam

Este documento presenta la solución para el mismo problema de entrenamiento aplicando el algoritmo de optimización **Adam** (**A**daptive **M**oment **E**stimation).

Diagrama de la Red




Figure 1: Diagrama de la Red Neuronal

Autor: Dr. Aboud Barsekh Onji **Institución:** IPN - Universidad Anáhuac México

1. Planteamiento del Problema

Se tiene una red neuronal multicapa con la siguiente configuración:

- **Arquitectura:** 2 Entradas - 2 Ocultas - 2 Salidas.
- **Entradas:** $x_1 = 0.35$, $x_2 = 0.8$.
- **Salida Deseada:** $t = 0.5$ ($t_1 = 0.5, t_2 = 0.5$).
- **Hiperparámetros de Adam:**
 - Tasa de Aprendizaje (η): 0.2. (Nota: En aplicaciones reales de Adam, se suelen usar tasas menores como 0.001, pero mantenemos 0.2 para consistencia con el ejercicio original).
 - β_1 : 0.9 (Decaimiento del primer momento).

- β_2 : 0.999 (Decaimiento del segundo momento).
 - ϵ : 10^{-8} (Para evitar división por cero).
 - **Función de Activación:** Log-Sigmoid.
-

2. Fase 1: Propagación hacia Adelante

Idéntico al original.

Capa Oculta: * $out_{h1} \approx 0.5486$ * $out_{h2} \approx 0.6502$

Capa de Salida: * $out_{o1} \approx 0.5731$ * $out_{o2} \approx 0.6548$

3. Fase 2: Cálculo del Error y Gradientes

Calculamos los gradientes locales δ .

Capa de Salida: * $\delta_{o1} \approx 0.0179$ * $\delta_{o2} \approx 0.0350$

Capa Oculta: * $\delta_{h1} \approx 0.0022$ * $\delta_{h2} \approx 0.0080$

4. Fase 3: Actualización de Pesos con Adam

El algoritmo Adam mantiene estimaciones del promedio (m) y la varianza no centrada (v) de los gradientes.

Fórmulas Adam (para $t = 1$)

Para cada peso, definimos el gradiente $g = \nabla E = \delta \cdot input$. Asumimos $m_0 = 0$ y $v_0 = 0$.

1. **Primer Momento (Media):** $m_1 = \beta_1 m_0 + (1 - \beta_1)g = (1 - 0.9)g = 0.1g$
2. **Segundo Momento (Varianza):** $v_1 = \beta_2 v_0 + (1 - \beta_2)g^2 = (1 - 0.999)g^2 = 0.001g^2$
3. **Corrección de Sesgo (Bias Correction):**
 - $\hat{m}_1 = \frac{m_1}{1 - \beta_1^1} = \frac{0.1g}{0.1} = g$
 - $\hat{v}_1 = \frac{v_1}{1 - \beta_2^1} = \frac{0.001g^2}{0.001} = g^2$
4. **Actualización:**

$$w_{new} = w_{old} - \eta \frac{\hat{m}_1}{\sqrt{\hat{v}_1} + \epsilon}$$

Análisis Crítico del Paso 1: Sustituyendo $\hat{m}_1 = g$ y $\hat{v}_1 = g^2$:

$$\Delta w = -\eta \frac{g}{\sqrt{g^2} + \epsilon} \approx -\eta \frac{g}{|g|} = -\eta \cdot \text{signo}(g)$$

Esto significa que en la primera iteración, Adam realiza un paso de magnitud casi fija η (0.2) en la dirección opuesta al gradiente. Esto resultará en cambios de peso drásticos.

Actualización Capa Oculta $\rightarrow$ Salida

Peso $w_{11}^{(2)}$: * Gradiente $g = \delta_{o1} \cdot out_{h1} = 0.0179 \cdot 0.5486 = 0.00982$ * Como $g > 0$, el paso será aprox -0.2 . * Cálculo exacto: * $\hat{m} = 0.00982$ * $\hat{v} = (0.00982)^2 = 0.0000964$ * $\Delta w = -0.2 \frac{0.00982}{\sqrt{0.0000964}} = -0.2(1) = -0.2$ * $w_{11}^{(2)+} = 0.3 - 0.2 =$
0.1000

Peso $w_{21}^{(2)}$: * Gradiente $g = 0.01164 (> 0)$ * $w_{21}^{(2)+} = 0.2 - 0.2 =$
0.0000

Peso $w_{12}^{(2)}$: * Gradiente $g = 0.01920 (> 0)$ * $w_{12}^{(2)+} = 0.1 - 0.2 =$
-0.1000

Peso $w_{22}^{(2)}$: * Gradiente $g = 0.02276 (> 0)$ * $w_{22}^{(2)+} = 0.9 - 0.2 =$
0.7000

Actualización Capa Entrada $\rightarrow$ Oculta

Peso $w_{11}^{(1)}$: * Gradiente $g = \delta_{h1} \cdot x_1 = 0.0022 \cdot 0.35 = 0.00077 (> 0)$ * $w_{11}^{(1)+} =$
 $0.1 - 0.2 =$
-0.1000

Peso $w_{21}^{(1)}$: * Gradiente $g = 0.00176 (> 0)$ * $w_{21}^{(1)+} = 0.2 - 0.2 =$
0.0000

Peso $w_{12}^{(1)}$: * Gradiente $g = 0.0028 (> 0)$ * $w_{12}^{(1)+} = 0.4 - 0.2 =$
0.2000

Peso $w_{22}^{(1)}$: * Gradiente $g = 0.0064 (> 0)$ * $w_{22}^{(1)+} = 0.6 - 0.2 =$
0.4000

Resumen y Comparación

Debido a que $\eta = 0.2$ es una tasa de aprendizaje extremadamente alta para Adam, y a que en la primera iteración Adam normaliza el gradiente por su propia magnitud, los pesos han sufrido cambios masivos de ± 0.2 .

Peso	Original	SGD ($\eta = 0.2$)	Adam ($\eta = 0.2$)
Capa 2			
$w_{11}^{(2)}$	0.3	0.2980	0.1000
$w_{21}^{(2)}$	0.2	0.1977	0.0000
$w_{12}^{(2)}$	0.1	0.0962	-0.1000
$w_{22}^{(2)}$	0.9	0.8954	0.7000
Capa 1			
$w_{11}^{(1)}$	0.1	0.0998	-0.1000

Peso	Original	SGD ($\eta = 0.2$)	Adam ($\eta = 0.2$)
$w_{12}^{(1)}$	0.4	0.3994	0.2000
$w_{22}^{(1)}$	0.6	0.5987	0.4000

Conclusión: Este ejercicio demuestra por qué Adam requiere tasas de aprendizaje mucho menores (típicamente entre 0.0001 y 0.001). Con $\eta = 0.2$, Adam se vuelve inestable y da pasos demasiado grandes (“Overshooting”).