

Solución Paso a Paso: Problema de Examen de Redes Neuronales

Este documento presenta la solución detallada para el problema de entrenamiento (un paso de Backpropagation) de acuerdo con la siguiente red neuronal.

Diagrama de la Red




Figure 1: Diagrama de la Red Neuronal

Autor: Dr. Aboud Barsekh Onji **Institución:** IPN - Universidad Anáhuac México

1. Planteamiento del Problema

Se tiene una red neuronal multicapa con la siguiente configuración:

- **Arquitectura:** 2 Entradas - 2 Ocultas - 2 Salidas.
- **Entradas (X):** $x_1 = 0.35$, $x_2 = 0.8$.
- **Salida Deseada ($Target$):** $t = 0.5$ (Asumiremos $t_1 = 0.5$ y $t_2 = 0.5$ dado que la red tiene dos salidas).
- **Tasa de Aprendizaje (η):** 0.2.
- **Función de Activación:** Log-Sigmoid para todas las neuronas:

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Derivada: $\sigma'(z) = \sigma(z)(1 - \sigma(z))$.

Pesos Iniciales (Asumidos e Interpretados del Diagrama)

Capa 1 (Entrada $\rightarrow$ Oculta): * $w_{11}^{(1)} = 0.1$ (de x_1 a h_1) * $w_{21}^{(1)} = 0.2$ (de x_2 a h_1) [*Dato inferido*] * $w_{12}^{(1)} = 0.4$ (de x_1 a h_2) * $w_{22}^{(1)} = 0.6$ (de x_2 a h_2)

Capa 2 (Oculta $\rightarrow$ Salida): * $w_{11}^{(2)} = 0.3$ (de h_1 a o_1) * $w_{21}^{(2)} = 0.2$ (de h_2 a o_1) [*Dato inferido*] * $w_{12}^{(2)} = 0.1$ (de h_1 a o_2) [*Dato inferido*] * $w_{22}^{(2)} = 0.9$ (de h_2 a o_2)

2. Fase 1: Propagación hacia Adelante (Forward Propagation)

Calculamos la entrada neta (*net*) y la salida (*out*) de cada neurona.

Capa Oculta (H)

Neurona h_1 :

$$net_{h1} = x_1 w_{11}^{(1)} + x_2 w_{21}^{(1)} = (0.35)(0.1) + (0.8)(0.2)$$

$$net_{h1} = 0.035 + 0.16 = \mathbf{0.195}$$

$$out_{h1} = \frac{1}{1 + e^{-0.195}} \approx \mathbf{0.5486}$$

Neurona h_2 :

$$net_{h2} = x_1 w_{12}^{(1)} + x_2 w_{22}^{(1)} = (0.35)(0.4) + (0.8)(0.6)$$

$$net_{h2} = 0.14 + 0.48 = \mathbf{0.62}$$

$$out_{h2} = \frac{1}{1 + e^{-0.62}} \approx \mathbf{0.6502}$$

Capa de Salida (O)

Neurona o_1 :

$$net_{o1} = out_{h1} w_{11}^{(2)} + out_{h2} w_{21}^{(2)} = (0.5486)(0.3) + (0.6502)(0.2)$$

$$net_{o1} = 0.16458 + 0.13004 = \mathbf{0.2946}$$

$$out_{o1} = \frac{1}{1 + e^{-0.2946}} \approx \mathbf{0.5731}$$

Neurona o_2 :

$$net_{o2} = out_{h1} w_{12}^{(2)} + out_{h2} w_{22}^{(2)} = (0.5486)(0.1) + (0.6502)(0.9)$$

$$net_{o2} = 0.05486 + 0.58518 = \mathbf{0.6400}$$

$$out_{o2} = \frac{1}{1 + e^{-0.6400}} \approx \mathbf{0.6548}$$

3. Fase 2: Cálculo del Error y Retropropagación (Back-propagation)

Calculamos los gradientes (δ) comenzando desde la salida hacia atrás.

Error en la Salida

Asumiendo la función de error cuadrático medio $E = \frac{1}{2}(t - out)^2$.

Para o_1 (Target $t_1 = 0.5$):

$$\delta_{o1} = (out_{o1} - t_1) \cdot out_{o1}(1 - out_{o1})$$

$$\delta_{o1} = (0.5731 - 0.5) \cdot 0.5731(1 - 0.5731)$$

$$\delta_{o1} = (0.0731) \cdot (0.2446) \approx \mathbf{0.0179}$$

Para o_2 (Target $t_2 = 0.5$):

$$\delta_{o2} = (out_{o2} - t_2) \cdot out_{o2}(1 - out_{o2})$$

$$\delta_{o2} = (0.6548 - 0.5) \cdot 0.6548(1 - 0.6548)$$

$$\delta_{o2} = (0.1548) \cdot (0.2260) \approx \mathbf{0.0350}$$

Error en la Capa Oculta

Propagamos el error hacia atrás ponderado por los pesos.

Para h_1 :

$$\delta_{h1} = (\delta_{o1}w_{11}^{(2)} + \delta_{o2}w_{12}^{(2)}) \cdot out_{h1}(1 - out_{h1})$$

$$\delta_{h1} = [(0.0179)(0.3) + (0.0350)(0.1)] \cdot 0.5486(1 - 0.5486)$$

$$\delta_{h1} = [0.00537 + 0.0035] \cdot 0.2476$$

$$\delta_{h1} = 0.00887 \cdot 0.2476 \approx \mathbf{0.0022}$$

Para h_2 :

$$\delta_{h2} = (\delta_{o1}w_{21}^{(2)} + \delta_{o2}w_{22}^{(2)}) \cdot out_{h2}(1 - out_{h2})$$

$$\delta_{h2} = [(0.0179)(0.2) + (0.0350)(0.9)] \cdot 0.6502(1 - 0.6502)$$

$$\delta_{h2} = [0.00358 + 0.0315] \cdot 0.2274$$

$$\delta_{h2} = 0.03508 \cdot 0.2274 \approx \mathbf{0.0080}$$

4. Fase 3: Actualización de Pesos

Regla de actualización: $w_{new} = w_{old} - \eta \cdot \delta \cdot input$.

Actualización Capa Oculta $\rightarrow$ Salida

$$w_{11}^{(2)+} = 0.3 - 0.2(0.0179)(0.5486) = 0.3 - 0.00196 = \mathbf{0.2980}$$

$$w_{21}^{(2)+} = 0.2 - 0.2(0.0179)(0.6502) = 0.2 - 0.00233 = \mathbf{0.1977}$$

$$w_{12}^{(2)+} = 0.1 - 0.2(0.0350)(0.5486) = 0.1 - 0.00384 = \mathbf{0.0962}$$

$$w_{22}^{(2)+} = 0.9 - 0.2(0.0350)(0.6502) = 0.9 - 0.00455 = \mathbf{0.8954}$$

Actualización Capa Entrada $\rightarrow$ Oculta

$$w_{11}^{(1)+} = 0.1 - 0.2(0.0022)(0.35) = 0.1 - 0.00015 = \mathbf{0.0998}$$

$$w_{21}^{(1)+} = 0.2 - 0.2(0.0022)(0.80) = 0.2 - 0.00035 = \mathbf{0.1996}$$

$$w_{12}^{(1)+} = 0.4 - 0.2(0.0080)(0.35) = 0.4 - 0.00056 = \mathbf{0.3994}$$

$$w_{22}^{(1)+} = 0.6 - 0.2(0.0080)(0.80) = 0.6 - 0.00128 = \mathbf{0.5987}$$

Resumen de Resultados

Peso	Valor Original	Nuevo Valor
Capa 2		
$w_{11}^{(2)}$	0.3	0.2980
$w_{22}^{(2)}$	0.9	0.8954
Capa 1		
$w_{11}^{(1)}$	0.1	0.0998
$w_{12}^{(1)}$	0.4	0.3994
$w_{22}^{(1)}$	0.6	0.5987

Nota: Los valores han sido redondeados a 4 decimales para claridad.

Apéndice: Derivación Matemática de δ_{o1}

Para comprender la transición entre la función de error global y la fórmula específica de actualización para la neurona de salida, aplicamos el cálculo multivariable, específicamente la **Regla de la Cadena**.

1. Definiciones de Control

De acuerdo con el planteamiento del problema, utilizamos los siguientes componentes: * **Función de Error Cuadrático Medio (E):** $E = \frac{1}{2}(t - out)^2$. * **Función de Activación (Log-Sigmoid):** $out = \sigma(net) = \frac{1}{1+e^{-net}}$. * **Derivada de la Activación:** $\sigma'(net) = out(1 - out)$.

2. El Concepto de Gradiente Local (δ)

El valor δ_{o1} representa la sensibilidad del error total respecto a la entrada neta de la neurona de salida. Matemáticamente:

$$\delta_{o1} = \frac{\partial E}{\partial net_{o1}}$$

3. Desglose por Regla de la Cadena

Como el error no depende directamente de la entrada neta (net), sino de la salida final (out), desglosamos la derivada en dos eslabones:

$$\delta_{o1} = \underbrace{\frac{\partial E}{\partial out_{o1}}}_{\text{Parte A}} \cdot \underbrace{\frac{\partial out_{o1}}{\partial net_{o1}}}_{\text{Parte B}}$$

Parte A: Derivada del Error respecto a la Salida Derivamos la función $E = \frac{1}{2}(t_1 - out_{o1})^2$ con respecto a out_{o1} : 1. Bajamos el exponente (2), que se cancela con el coeficiente $\frac{1}{2}$. 2. Mantenemos el término interno: $(t_1 - out_{o1})$. 3. Multiplicamos por la derivada interna de $-out_{o1}$, que es -1 . 4. **Resultado:** $-(t_1 - out_{o1})$, lo cual se reescribe como $(out_{o1} - t_1)$.

Parte B: Derivada de la Salida respecto a la Entrada Neta Esta parte corresponde a la derivada de la función de activación logística: * **Resultado:** $out_{o1}(1 - out_{o1})$.

4. Ecuación Resultante

Al unir ambos componentes, obtenemos la fórmula final utilizada en el cálculo del examen:

$$\delta_{o1} = (out_{o1} - t_1) \cdot out_{o1}(1 - out_{o1})$$

Nota: Este valor de delta es el que se multiplica posteriormente por la tasa de aprendizaje (η) y la entrada (input) para actualizar los pesos de la capa de salida.