

Support Vector Machines (SVM): Fundamentos Teóricos

Autor: Prof. D.Sc. BARSEKH-ONJI Aboud **Institución:** Facultad de Ingeniería, Universidad Anáhuac México **Curso:** Redes Neuronales y SVM **Contacto:** aboud.barsekh@anahuac.mx **ORCID:** 0009-0004-5440-8092

Tabla de Contenido

1. Contexto y Motivación
 2. El Problema de Clasificación Binaria
 3. Hiperplano de Margen Máximo
 4. Formulación del Problema Primal
 5. Dualidad de Lagrange y Condiciones KKT
 6. El Problema Dual
 7. SVM de Margen Suave (Soft Margin)
 8. El Truco del Kernel
 9. Kernels Fundamentales
 10. SVM Multi-clase
 11. Support Vector Regression (SVR)
 12. Complejidad Computacional y Algoritmos de Solución
 13. Selección de Hiperparámetros
 14. Ventajas, Limitaciones y Comparativa
 15. Referencias
-

1. Contexto y Motivación

1.1 Origen histórico

Las **Máquinas de Vectores de Soporte** (*Support Vector Machines*, SVM) fueron introducidas por Vladimir Vapnik y Corinna Cortes en 1995, consolidando décadas de trabajo teórico de Vapnik en la *Teoría del Aprendizaje Estadístico* (*Statistical Learning Theory*, SLT) desarrollada desde los años 60 en colaboración con Alexey Chervonenkis.

El modelo SVM no surgió como una intuición heurística, sino como la consecuencia directa de un principio teórico sólido: la **minimización del riesgo estructural** (*Structural Risk Minimization*, SRM). Este principio sostiene que el error de generalización de un modelo está acotado por la suma del error de entrenamiento y un término de complejidad del modelo que depende de la dimensión VC (*Vapnik-Chervonenkis dimension*).

Formalmente, con probabilidad al menos $1 - \delta$ sobre la elección del conjunto de entrenamiento de tamaño N , el error de generalización R satisface:

$$R \leq R_{\text{emp}} + \sqrt{\frac{h \left(\ln \frac{2N}{h} + 1 \right) - \ln \frac{\delta}{4}}{N}}$$

donde R_{emp} es el error empírico (de entrenamiento), h es la dimensión VC del modelo y N es el número de muestras. Esta cota formaliza por qué modelos más simples generalizan mejor: el término de regularización crece con h .

SVM controla h directamente maximizando el margen de separación, lo que conduce de forma natural a un problema de optimización convexo con garantías teóricas de unicidad y globalidad.

1.2 ¿Por qué estudiar SVM en el contexto de redes neuronales?

SVM y las redes neuronales comparten el objetivo de aprender una función $f : \mathbb{R}^d \rightarrow \mathcal{Y}$ a partir de datos, pero difieren fundamentalmente en su enfoque:

Aspecto	Redes Neuronales	SVM
Principio	Minimización empírica del riesgo	Minimización estructural del riesgo
Optimización	No convexa (múltiples mínimos locales)	Convexa (mínimo global único)
Parámetros	Millones (pesos sinápticos)	Pocos (vectores de soporte + C, γ)
Garantías	Heurísticas (backpropagation)	Teóricas (cota VC)
Eficiencia	Requiere muchos datos	Funciona con muestras pequeñas
Kernel	Implícito (capas ocultas)	Explícito y elegible

Comprender SVM profundiza la intuición sobre separabilidad, representación de datos en espacios de características, y el balance entre sesgo y varianza.

2. El Problema de Clasificación Binaria

2.1 Notación y formulación del problema

Dado un **conjunto de entrenamiento** de N pares entrada-salida:

$$\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^N, \quad \mathbf{x}_i \in \mathbb{R}^d, \quad y_i \in \{-1, +1\}$$

El objetivo de clasificación binaria es encontrar una función $f : \mathbb{R}^d \rightarrow \{-1, +1\}$ que generalice correctamente a nuevas muestras no vistas.

Un **clasificador lineal** tiene la forma:

$$f(\mathbf{x}) = \text{sign}(\mathbf{w}^\top \mathbf{x} + b)$$

donde $\mathbf{w} \in \mathbb{R}^d$ es el **vector de pesos** (normal al hiperplano) y $b \in \mathbb{R}$ es el **sesgo** (*bias* o término independiente). La función $\text{sign}(z)$ devuelve $+1$ si $z > 0$ y -1 si $z < 0$.

Geoméricamente, el hiperplano $\mathcal{H} = \{\mathbf{x} \in \mathbb{R}^d : \mathbf{w}^\top \mathbf{x} + b = 0\}$ divide el espacio en dos semiespacios:

- $\mathcal{H}^+ = \{\mathbf{x} : \mathbf{w}^\top \mathbf{x} + b > 0\} \rightarrow \text{clase } +1$
- $\mathcal{H}^- = \{\mathbf{x} : \mathbf{w}^\top \mathbf{x} + b < 0\} \rightarrow \text{clase } -1$

2.2 El problema de la ambigüedad: infinitos separadores

Cuando los datos son **linealmente separables**, existen infinitos hiperplanos que los separan correctamente. El perceptrón de Rosenblatt (1958) converge a *alguno* de ellos, dependiendo de la inicialización y el orden de presentación de los datos, sin garantías sobre cuál elige. Esto es problemático porque hiperplanos que se ajustan demasiado al entrenamiento pueden tener pobre generalización.

SVM responde a esta ambigüedad con un criterio geométrico riguroso: elegir el hiperplano que **maximiza la distancia mínima** entre él y los puntos de entrenamiento de ambas clases. Este es el principio del **margen máximo**.

3. Hiperplano de Margen Máximo

3.1 Distancia de un punto a un hiperplano

La distancia euclidiana de un punto $\mathbf{x}_i$ al hiperplano $\mathbf{w}^\top \mathbf{x} + b = 0$ es:

$$d(\mathbf{x}_i, \mathcal{H}) = \frac{|\mathbf{w}^\top \mathbf{x}_i + b|}{\|\mathbf{w}\|}$$

donde $\|\mathbf{w}\| = \sqrt{\mathbf{w}^\top \mathbf{w}}$ es la norma euclidiana del vector de pesos. El denominador $\|\mathbf{w}\|$ es indispensable: sin él, la expresión $\mathbf{w}^\top \mathbf{x}_i + b$ es solo un valor escalar que escala con la magnitud de $\mathbf{w}$, no una distancia geométrica.

Para un punto **correctamente clasificado** de clase y_i , el signo de $\mathbf{w}^\top \mathbf{x}_i + b$ coincide con el signo de y_i . Esto permite escribir la distancia con signo (siempre positiva para puntos correctamente clasificados) como:

$$d_i = \frac{y_i(\mathbf{w}^\top \mathbf{x}_i + b)}{\|\mathbf{w}\|}$$

Esta es la **distancia funcional con corrección de clase**. Si el punto está correctamente clasificado, $d_i > 0$; si está mal clasificado, $d_i < 0$.

3.2 Definición de margen y vectores de soporte

El **margen geométrico** de un clasificador $(\mathbf{w}, b)$ respecto a un conjunto de datos $\mathcal{D}$ es la distancia mínima entre cualquier punto de entrenamiento y el hiperplano:

$$\rho(\mathbf{w}, b) = \min_{i=1, \dots, N} \frac{y_i(\mathbf{w}^\top \mathbf{x}_i + b)}{\|\mathbf{w}\|}$$

Los puntos de entrenamiento que alcanzan este mínimo, es decir, los más cercanos al hiperplano, se denominan **vectores de soporte** (*support vectors*). Son los únicos puntos que, en última instancia, determinan la posición del hiperplano óptimo.

Propiedad fundamental: Si se eliminan todos los puntos de entrenamiento excepto los vectores de soporte, el hiperplano óptimo no cambia.

3.3 Normalización canónica

Por conveniencia algebraica, se impone la **normalización canónica**: se escala $(\mathbf{w}, b)$ de modo que los vectores de soporte satisfagan exactamente:

$$y_i(\mathbf{w}^\top \mathbf{x}_i + b) = 1$$

Con esta convención, los vectores de soporte de clase $+1$ se encuentran sobre el hiperplano $\mathbf{w}^\top \mathbf{x} + b = +1$, y los de clase -1 sobre $\mathbf{w}^\top \mathbf{x} + b = -1$.

La distancia de cada hiperplano de margen al hiperplano central es:

$$d_+ = \frac{y_i(\mathbf{w}^\top \mathbf{x}_i + b)}{\|\mathbf{w}\|} = \frac{1 \cdot 1}{\|\mathbf{w}\|} = \frac{1}{\|\mathbf{w}\|}$$

El margen total (suma de las dos distancias) es:

$$\rho = \frac{1}{\|\mathbf{w}\|} + \frac{1}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}$$

Maximizar el margen $\rho = 2/\|\mathbf{w}\|$ es equivalente a **minimizar** $\|\mathbf{w}\|$, o por conveniencia diferencial, minimizar $\frac{1}{2}\|\mathbf{w}\|^2$.

4. Formulación del Problema Primal

4.1 Problema de optimización (caso separable)

Con la normalización canónica, el problema de margen máximo se escribe formalmente como:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{s.a.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad \forall i = 1, \dots, N \end{aligned}$$

Este es un problema de **programación cuadrática convexa** (*Quadratic Programming*, QP):

- La función objetivo $\frac{1}{2} \|\mathbf{w}\|^2$ es **cuadrática y convexa**
- Las restricciones son **lineales** en $(\mathbf{w}, b)$
- La región factible (intersección de semiespacios) es **convexa**

Por la teoría de optimización convexa, este problema tiene **solución única** (mínimo global), lo que diferencia fundamentalmente a SVM de las redes neuronales (cuya función de pérdida es no convexa con múltiples mínimos locales).

4.2 Interpretación geométrica del problema

Las N restricciones $y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1$ establecen que:

- Todos los puntos de clase $+1$ deben estar en el semiplano $\mathbf{w}^\top \mathbf{x} + b \geq 1$
- Todos los puntos de clase -1 deben estar en el semiplano $\mathbf{w}^\top \mathbf{x} + b \leq -1$
- La región $-1 < \mathbf{w}^\top \mathbf{x} + b < 1$ es la **franja de margen**, que debe estar vacía de puntos de entrenamiento

Minimizar $\|\mathbf{w}\|^2$ maximiza la anchura de esta franja.

5. Dualidad de Lagrange y Condiciones KKT

5.1 El Lagrangiano del problema primal

Para resolver el problema con restricciones de desigualdad, se introduce el **Lagrangiano**. Se asocia un multiplicador de Lagrange $\alpha_i \geq 0$ a cada restricción:

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^N \alpha_i [y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1]$$

La estrategia de Lagrange convierte el problema con restricciones en uno sin restricciones: el punto de silla del Lagrangiano (mínimo respecto a $\mathbf{w}, b$ y máximo respecto a $\boldsymbol{\alpha}$) coincide con la solución del problema original.

5.2 Condiciones de optimalidad KKT

Las condiciones de Karush-Kuhn-Tucker (KKT) son necesarias y suficientes para la optimalidad en problemas convexos. Se derivan igualando a cero las derivadas parciales del Lagrangiano:

Condición sobre $\mathbf{w}$:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i = 0 \quad \Rightarrow \quad \mathbf{w}^* = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$$

Condición sobre b :

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0 \quad \Rightarrow \quad \sum_{i=1}^N \alpha_i y_i = 0$$

Condición de holgura complementaria:

$$\alpha_i [y_i(\mathbf{w}^\top \mathbf{x}_i + b) - 1] = 0, \quad \forall i$$

Esta última condición es clave: o bien $\alpha_i = 0$ (el punto i no es vector de soporte y no participa en la solución), o bien $y_i(\mathbf{w}^\top \mathbf{x}_i + b) = 1$ (el punto i está exactamente sobre el margen y es un vector de soporte).

5.3 Representación del hiperplano en términos de los datos

La condición $\mathbf{w}^* = \sum_{i=1}^N \alpha_i y_i \mathbf{x}_i$ tiene una profunda implicación: el vector normal al hiperplano óptimo es una **combinación lineal de los vectores de soporte**. Solo los puntos con $\alpha_i > 0$ contribuyen. La solución es *dispersa* en el espacio de datos.

6. El Problema Dual

6.1 Derivación del dual

Sustituyendo las condiciones KKT en el Lagrangiano:

$$\mathcal{L} = \frac{1}{2} \left\| \sum_i \alpha_i y_i \mathbf{x}_i \right\|^2 - \sum_i \alpha_i y_i \mathbf{x}_i^\top \left(\sum_j \alpha_j y_j \mathbf{x}_j \right) - b \underbrace{\sum_i \alpha_i y_i}_{=0} + \sum_i \alpha_i$$

Simplificando, se obtiene el **problema dual de Wolfe**:

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & W(\boldsymbol{\alpha}) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{s.a.} \quad & \alpha_i \geq 0 \quad \text{y} \quad \sum_{i=1}^N \alpha_i y_i = 0 \end{aligned}$$

6.2 Propiedades del problema dual

El dual presenta ventajas importantes sobre el primal:

1. **La dimensión del problema es N (número de muestras)**, no d (dimensión del espacio de características). Esto es favorable cuando $d \gg N$.
2. **Solo aparecen productos internos $\mathbf{x}_i^\top \mathbf{x}_j$** , lo que abre la puerta directa al truco del kernel.
3. **La función objetivo es cóncava** (maximización de forma cuadrática negativa semi-definida), garantizando solución global.

6.3 Recuperación de los parámetros del modelo

Una vez resuelto el dual y obtenidos $\boldsymbol{\alpha}^*$:

$$\mathbf{w}^* = \sum_{i \in SV} \alpha_i^* y_i \mathbf{x}_i$$

El sesgo b^* se recupera usando cualquier vector de soporte $\mathbf{x}_k$ (con $\alpha_k^* > 0$):

$$b^* = y_k - \mathbf{w}^{*\top} \mathbf{x}_k = y_k - \sum_{i \in SV} \alpha_i^* y_i \mathbf{x}_i^\top \mathbf{x}_k$$

En la práctica, se promedia sobre todos los vectores de soporte para mayor estabilidad numérica:

$$b^* = \frac{1}{|SV|} \sum_{k \in SV} \left(y_k - \sum_{i \in SV} \alpha_i^* y_i \mathbf{x}_i^\top \mathbf{x}_k \right)$$

6.4 Función de decisión final

La clasificación de un nuevo punto $\mathbf{x}$ se realiza con:

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i \in SV} \alpha_i^* y_i \mathbf{x}_i^\top \mathbf{x} + b^* \right)$$

Solo participan los vectores de soporte, lo que hace la predicción eficiente en memoria y tiempo.

7. SVM de Margen Suave (Soft Margin)

7.1 Motivación: datos no separables linealmente

El caso del margen duro asume que los datos son **perfectamente separables**, lo cual raramente ocurre en problemas reales por dos razones:

1. **Ruido en las etiquetas**: un punto puede estar etiquetado incorrectamente
2. **Solapamiento intrínseco**: las distribuciones de las clases se solapan en el espacio de características

Si los datos no son separables, el problema primal no tiene solución factible. La solución es **relajar las restricciones** permitiendo que algunos puntos violen el margen, penalizando estas violaciones en la función objetivo.

7.2 Variables de holgura

Se introduce una variable de holgura (*slack variable*) $\xi_i \geq 0$ para cada punto:

$$y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i$$

La interpretación geométrica de ξ_i es:

- $\xi_i = 0$: el punto está correctamente clasificado y fuera del margen
- $0 < \xi_i \leq 1$: el punto está dentro del margen pero correctamente clasificado
- $\xi_i = 1$: el punto está exactamente sobre el hiperplano separador
- $\xi_i > 1$: el punto está mal clasificado (en el semiplano incorrecto)

El **error de clasificación** del punto i es $\mathbf{1}[\xi_i > 1]$, y el número total de errores está acotado por $\sum_i \xi_i$.

7.3 Formulación del Soft Margin SVM

$$\min_{\mathbf{w}, b, \xi} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i$$

$$\text{s.a.} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad \forall i$$

El **parámetro de regularización** $C > 0$ controla el balance entre:

- Maximizar el margen (minimizar $\|\mathbf{w}\|^2$)
- Minimizar las violaciones del margen (minimizar $\sum \xi_i$)

7.4 Interpretación de C y su conexión con la regularización

C actúa como el recíproco de un parámetro de regularización clásico:

Valor de C	Comportamiento	Riesgo
$C \rightarrow \infty$	Penaliza fuertemente los errores $\rightarrow$ margen duro	<i>Overfitting</i>
C grande (e.g., 10^3)	Pocos errores permitidos, margen estrecho	<i>Overfitting</i> moderado
$C = 1$	Balance equilibrado (valor por defecto en muchas implementaciones)	—
C pequeño (e.g., 10^{-2})	Muchos errores permitidos, margen ancho	<i>Underfitting</i>
$C \rightarrow 0$	Ignora los errores $\rightarrow$ clasificador trivial	<i>Underfitting</i>

La función de pérdida asociada a las variables de holgura es la **pérdida bisagra** (*hinge loss*):

$$\ell(y_i, f(\mathbf{x}_i)) = \max(0, 1 - y_i f(\mathbf{x}_i))$$

donde $f(\mathbf{x}_i) = \mathbf{w}^\top \mathbf{x}_i + b$ (sin sign). La función objetivo del Soft Margin SVM puede reescribirse como:

$$\min_{\mathbf{w}, b} \quad \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i(\mathbf{w}^\top \mathbf{x}_i + b))$$

Esta forma conecta SVM con la familia de modelos de regularización ℓ_2 con pérdida bisagra.

7.5 Problema dual del Soft Margin

El dual es idéntico al del caso separable, con la única diferencia de una **cota superior** en los multiplicadores:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{s.a.} \quad & 0 \leq \alpha_i \leq C, \quad \sum_{i=1}^N \alpha_i y_i = 0 \end{aligned}$$

Los multiplicadores ahora se clasifican en tres grupos:

- $\alpha_i = 0$: punto interior, bien clasificado, fuera del margen
 - $0 < \alpha_i < C$: vector de soporte en el margen ($\xi_i = 0$)
 - $\alpha_i = C$: punto con violación del margen ($\xi_i > 0$), llamado *bounded support vector*
-

8. El Truco del Kernel

8.1 Motivación: datos no separables no linealmente

Cuando los datos no son linealmente separables en $\mathbb{R}^d$, la idea es mapearlos a un espacio de mayor dimensión (posiblemente infinita) $\mathcal{H}$ donde sí sean separables:

$$\phi : \mathbb{R}^d \rightarrow \mathcal{H}, \quad \mathbf{x} \mapsto \phi(\mathbf{x})$$

En $\mathcal{H}$ se aplica SVM lineal, y la frontera de decisión en el espacio original $\mathbb{R}^d$ resulta no lineal.

Ejemplo ilustrativo. Supóngase que $\mathbf{x} = (x_1, x_2) \in \mathbb{R}^2$ y se define:

$$\phi(\mathbf{x}) = (x_1^2, \sqrt{2}x_1x_2, x_2^2) \in \mathbb{R}^3$$

Entonces:

$$\phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j) = x_{i1}^2 x_{j1}^2 + 2x_{i1}x_{i2}x_{j1}x_{j2} + x_{i2}^2 x_{j2}^2 = (\mathbf{x}_i^\top \mathbf{x}_j)^2$$

Es decir, el producto interno en $\mathbb{R}^3$ es equivalente a elevar al cuadrado el producto interno en $\mathbb{R}^2$, sin necesidad de calcular ϕ explícitamente.

8.2 Definición formal de función Kernel

Una función $K : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}$ es un **kernel válido** si existe un mapa ϕ tal que:

$$K(\mathbf{x}_i, \mathbf{x}_j) = \phi(\mathbf{x}_i)^\top \phi(\mathbf{x}_j)$$

La condición equivalente (sin necesidad de conocer ϕ) es el **Teorema de Mercer**: K es un kernel válido si y solo si para cualquier conjunto finito de puntos $\{\mathbf{x}_1, \dots, \mathbf{x}_N\}$, la **matriz de Gram $\mathbf{K}$** con entradas $K_{ij} = K(\mathbf{x}_i, \mathbf{x}_j)$ es **semidefinida positiva** (SDP):

$$\sum_{i,j} c_i c_j K(\mathbf{x}_i, \mathbf{x}_j) \geq 0, \quad \forall \{c_i\} \subset \mathbb{R}$$

8.3 El truco del kernel en el dual SVM

El problema dual solo involucra los datos a través de productos internos $\mathbf{x}_i^\top \mathbf{x}_j$. Sustituyendo por el kernel:

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j)$$

La función de decisión se convierte en:

$$f(\mathbf{x}) = \text{sign} \left(\sum_{i \in SV} \alpha_i^* y_i K(\mathbf{x}_i, \mathbf{x}) + b^* \right)$$

El costo computacional de entrenamiento y predicción **no depende de la dimensión de $\mathcal{H}$** (que puede ser infinita), sino del número de vectores de soporte. Esto es el **truco del kernel** (*kernel trick*).

9. Kernels Fundamentales

9.1 Kernel lineal

$$K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^\top \mathbf{x}_j$$

Corresponde a $\phi(\mathbf{x}) = \mathbf{x}$ (identidad). Genera una frontera de decisión lineal en el espacio original. Se recomienda como punto de partida y para problemas con $d \gg N$.

9.2 Kernel polinomial

$$K(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^\top \mathbf{x}_j + c)^d, \quad c \geq 0, d \in \mathbb{Z}^+$$

El parámetro c controla la influencia de los monomios de menor grado. Para $d = 2$ y $c = 1$, el mapa ϕ incluye todas las interacciones de segundo orden entre características. El espacio de características tiene dimensión $\binom{n+d}{d}$.

9.3 Kernel RBF (Gaussiano)

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2), \quad \gamma > 0$$

Es el kernel más utilizado en la práctica. El espacio de características inducido tiene **dimensión infinita** (se puede demostrar mediante la expansión en series de Taylor de la exponencial). El parámetro $\gamma = \frac{1}{2\sigma^2}$ controla el ancho de la gaussiana:

- γ pequeño (σ grande): función de similitud suave, influencia de largo alcance
- γ grande (σ pequeño): función de similitud estrecha, influencia local

El kernel RBF satisface la condición de Mercer ya que la función $\exp(-\gamma\|\mathbf{x}-\mathbf{x}'\|^2)$ es una función de correlación de un proceso gaussiano estacionario.

9.4 Kernel sigmoide

$$K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\kappa \mathbf{x}_i^\top \mathbf{x}_j + \theta)$$

Este kernel tiene conexión directa con las redes neuronales: una SVM con kernel sigmoide es equivalente a una red neuronal de una capa oculta. Sin embargo, **no siempre es semidefinido positivo** (no siempre es un kernel de Mercer válido para todos los valores de κ y θ), por lo que debe usarse con cuidado.

9.5 Tabla comparativa de kernels

Kernel	Frontera inducida	Hiperparámetros	Uso recomendado
Lineal	Hiperplano	Ninguno	$d \gg N$, texto, imágenes
Polinomial	Curva polinomial	c, d	Reconocimiento de imágenes
RBF	Fronteras suaves no lineales	γ	Uso general, punto de partida
Sigmoide	Similar a red neuronal	κ, θ	Casos específicos

10. SVM Multi-clase

SVM es intrínsecamente binario. Se extiende a K clases mediante descomposición en problemas binarios.

10.1 Uno contra el Resto (OvR — *One vs Rest*)

Se entrenan K clasificadores SVM. El clasificador k separa la clase k (etiqueta +1) de todas las demás clases agrupadas (etiqueta -1). La predicción para un nuevo punto $\mathbf{x}$ es:

$$\hat{y} = \arg \max_{k=1, \dots, K} f_k(\mathbf{x}) = \arg \max_k \left(\sum_{i \in SV_k} \alpha_i^{(k)} y_i^{(k)} K(\mathbf{x}_i, \mathbf{x}) + b_k \right)$$

Se requieren K problemas QP, cada uno con N muestras. El problema de clases **desbalanceadas** es una debilidad conocida de OvR.

10.2 Uno contra Uno (OvO — *One vs One*)

Se entrenan $\binom{K}{2} = K(K-1)/2$ clasificadores, uno para cada par de clases. Cada clasificador solo usa las muestras de las dos clases involucradas. La predicción se realiza por **votación mayoritaria**: la clase que gana más torneos binarios se asigna al punto.

OvO tiene mejor comportamiento con clases desbalanceadas (los clasificadores binarios solo ven muestras de dos clases a la vez) y es más estable numéricamente. MATLAB y scikit-learn usan OvO por defecto.

11. Support Vector Regression (SVR)

11.1 Formulación del ϵ -SVR

Para problemas de regresión, donde $y_i \in \mathbb{R}$, se define un **tubo de tolerancia** de anchura 2ϵ . Las predicciones dentro del tubo no generan error; solo las que lo superan contribuyen a la función objetivo.

$$\begin{aligned} \min_{\mathbf{w}, b, \xi, \xi^*} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N (\xi_i + \xi_i^*) \\ \text{s.a.} \quad & \begin{cases} y_i - (\mathbf{w}^\top \mathbf{x}_i + b) \leq \epsilon + \xi_i \\ (\mathbf{w}^\top \mathbf{x}_i + b) - y_i \leq \epsilon + \xi_i^* \\ \xi_i, \xi_i^* \geq 0 \end{cases} \end{aligned}$$

donde ξ_i y ξ_i^* son las holguras superior e inferior respectivamente.

11.2 Función de pérdida ϵ -insensible

La función de pérdida asociada al ϵ -SVR es:

$$\ell_\epsilon(y_i, f(\mathbf{x}_i)) = \max(0, |y_i - f(\mathbf{x}_i)| - \epsilon)$$

Esta pérdida es cero dentro del tubo y lineal fuera de él, a diferencia del error cuadrático de la regresión ordinaria. La función de regresión final tiene la misma forma que el clasificador SVM:

$$f(\mathbf{x}) = \sum_{i \in SV} (\alpha_i^* - \alpha_i^{**}) K(\mathbf{x}_i, \mathbf{x}) + b^*$$

donde α_i^* y α_i^{**} son los multiplicadores duales asociados a las holguras superior e inferior.

12. Complejidad Computacional y Algoritmos de Solución

12.1 Complejidad del entrenamiento

El problema dual SVM es un QP de tamaño $N \times N$. Los algoritmos directos (como los basados en factorización de Cholesky) tienen complejidad:

- **Tiempo:** $\mathcal{O}(N^2)$ a $\mathcal{O}(N^3)$
- **Memoria:** $\mathcal{O}(N^2)$ para almacenar la matriz de Gram

Esto hace que SVM sea impráctica para $N > 10^5$ con implementaciones directas.

12.2 Algoritmo SMO (*Sequential Minimal Optimization*)

John Platt (1998) propuso SMO como solución al problema de escala. En lugar de resolver el QP completo, SMO descompone el problema en subproblemas de **tamaño 2**: en cada iteración, selecciona dos multiplicadores α_i, α_j y los optimiza analíticamente mientras mantiene fijos los demás.

La actualización analítica es posible porque con solo dos variables la restricción $\sum \alpha_i y_i = 0$ se reduce a una ecuación en una incógnita. El proceso itera hasta convergencia (criterio KKT). SMO tiene complejidad empírica entre $\mathcal{O}(N)$ y $\mathcal{O}(N^2)$ según el problema.

MATLAB usa variantes de SMO en `fitcsvm` y `fitrsvm`.

12.3 Predicción

El tiempo de predicción para un nuevo punto es $\mathcal{O}(N_{SV})$ donde N_{SV} es el número de vectores de soporte. En la práctica, $N_{SV} \ll N$, haciendo la predicción muy eficiente.

13. Selección de Hiperparámetros

13.1 Hiperparámetros del modelo

Para SVM con kernel RBF, los hiperparámetros a ajustar son:

- $C > 0$: regularización (control de margen vs. errores)
- $\gamma > 0$: anchura del kernel RBF

Para kernel polinomial: C, d, c .

13.2 Búsqueda en grilla con validación cruzada

El procedimiento estándar es una **búsqueda en grilla logarítmica** con validación cruzada k -fold ($k = 5$ o $k = 10$):

$$C \in \{10^{-3}, 10^{-2}, \dots, 10^3\}, \quad \gamma \in \{10^{-5}, 10^{-4}, \dots, 10^1\}$$

Para cada par (C, γ) , se evalúa el error de validación cruzada. Se selecciona el par con menor error, y se entrena el modelo final con todos los datos de entrenamiento.

La grilla logarítmica es apropiada porque SVM es moderadamente insensible a cambios de un orden de magnitud en los hiperparámetros, pero muy sensible a cambios de varios órdenes.

13.3 Análisis de la frontera de decisión

Un indicador práctico de selección inadecuada de hiperparámetros:

- **Demasiados vectores de soporte** ($N_{SV} \approx N$): C demasiado pequeño o γ inadecuado $\rightarrow$ modelo demasiado simple
 - **Muy pocos vectores de soporte**: posible *overfitting* con C muy grande
-

14. Ventajas, Limitaciones y Comparativa

14.1 Ventajas teóricas y prácticas

- **Garantías teóricas**: el margen máximo minimiza la cota superior del error de generalización derivada de la teoría VC
- **Convexidad**: solución única y global, sin problemas de mínimos locales
- **Eficiencia en alta dimensión**: funciona bien cuando $d \gg N$ (texto, bioinformática)
- **Kernel trick**: permite fronteras no lineales en el espacio original sin costo adicional en alta dimensión
- **Esparsidad**: la solución depende solo de un subconjunto de los datos (vectores de soporte)
- **Robustez**: el margen máximo tiene efecto regularizador intrínseco

14.2 Limitaciones

- **Escala**: el entrenamiento es $\mathcal{O}(N^2)$ a $\mathcal{O}(N^3)$; no escala a grandes datasets
- **Selección de kernel**: la elección del kernel requiere conocimiento del dominio o búsqueda exhaustiva
- **Sin probabilidades nativas**: SVM produce una clase binaria, no una probabilidad. Se pueden obtener probabilidades mediante calibración de Platt, pero esto agrega complejidad
- **Sensibilidad a la escala de características**: siempre se debe normalizar
- **Interpretabilidad**: con kernels no lineales, el modelo es una caja negra

14.3 SVM en el panorama actual del Machine Learning

Con el auge del *Deep Learning* desde 2012, SVM ha cedido terreno en áreas como visión por computadora y procesamiento de lenguaje natural, donde las

redes neuronales profundas dominan. Sin embargo, SVM sigue siendo la opción preferida en:

- Datasets pequeños ($N < 10^4$) con alta dimensionalidad
 - Aplicaciones donde las garantías teóricas son relevantes (seguridad, medicina)
 - Problemas donde la interpretabilidad de los vectores de soporte es valiosa
 - Bioinformática, clasificación de texto, series de tiempo cortas
-

15. Referencias

- **Cortes, C. & Vapnik, V. (1995).** Support-Vector Networks. *Machine Learning*, 20(3), 273–297.
 - **Vapnik, V. (1998).** *Statistical Learning Theory*. Wiley-Interscience.
 - **Schölkopf, B. & Smola, A.J. (2002).** *Learning with Kernels: Support Vector Machines, Regularization, Optimization, and Beyond*. MIT Press.
 - **Bishop, C.M. (2006).** *Pattern Recognition and Machine Learning*. Springer. Capítulo 7.
 - **Platt, J. (1998).** Sequential Minimal Optimization: A Fast Algorithm for Training Support Vector Machines. *Technical Report MSR-TR-98-14*, Microsoft Research.
 - **Burges, C.J.C. (1998).** A Tutorial on Support Vector Machines for Pattern Recognition. *Data Mining and Knowledge Discovery*, 2(2), 121–167.
 - **Chang, C.C. & Lin, C.J. (2011).** LIBSVM: A library for support vector machines. *ACM Transactions on Intelligent Systems and Technology*, 2(3), 1–27.
 - **MathWorks (2024).** Statistics and Machine Learning Toolbox — `fitcsvm`. Disponible en: <https://www.mathworks.com/help/stats/fitcsvm.html>
-

Documento preparado para uso académico en el curso de Redes Neuronales y SVM, Facultad de Ingeniería, Universidad Anáhuac México.